Qusetion 3

Entrée [1]: | #changement des librairies

import numpy as np

import matplotlib.pyplot as plt

import pandas as pd

import seaborn as sns

SQ.1

Entrée [2]: #Lecture de la base smp smp=pd.read_csv("smp2.csv", sep=";")

Entrée [3]: print(smp)# tabulation de la base

0001	age .e \	prof	duree	discip	n.enfant	n.fratrie
0 1.0	31.0	autre	4.0	0.0	2.0	4
1.0 1 2.0	49.0	NaN	NaN	0.0	7.0	3
2 2.0	50.0	<pre>prof.intermediaire</pre>	5.0	0.0	2.0	2
3 1.0	47.0	ouvrier	NaN	0.0	0.0	6
4 1.0	23.0	sans emploi	4.0	1.0	1.0	6
• •	• • • •	•••	• • • •			• • • •
794 1.0	28.0	sans emploi	5.0	0.0	1.0	4
795 2.0	44.0	ouvrier	4.0	1.0	1.0	12
796 4.0	31.0	cadre	4.0	0.0	3.0	6
797 3.0	38.0	employe	5.0	0.0	0.0	1
798 1.0	71.0	autre	4.0	0.0	2.0	4
	conor	ation impo onfant	nlaco	cub	st cons s	cz conc ch

3		1.	0	0.0	1.0			0	0	1
.0 4 .0	2.0	1.	0	NaN	1.0			0	0	1
794 aN	3.0	Na	N	1.0	0.0			0	0	N
795	310	0.	0	0.0	0.0			0	0	1
.0	1.0									
796	1 0	1.	0	1.0	1.0	• • •		1	0	2
.0 797	1.0	0.	a	0.0	0.0			0	0	1
.0	1.0	01	·	010	010	•••		· ·	O	_
798		1.	0	0.0	0.0			0	0	1
.0	1.0									
	ed	dr	suicide.s	suic	ide.hr	suicide.	past	dur.inte	erv	
0	1.0	1.0	0.0		0.0		0.0		laN	
1	2.0	1.0	0.0		0.0		0.0	70	0.0	
2	3.0	2.0	0.0		0.0		0.0	N	laN	
3	2.0	2.0	1.0		0.0		0.0	105	0.0	
4	2.0	2.0	0.0		0.0		1.0	N	laN	
794	1.0	3.0	1.0		0.0		0.0		0.0	
795	1.0	1.0	0.0		0.0		1.0	105		
796	1.0	1.0	1.0		0.0		0.0	105		
797	1.0	1.0	0.0		0.0		0.0		0.0	
798	1.0	1.0	0.0		0.0		0.0	45	5.0	

[799 rows x 26 columns]

```
Entrée [4]: smp.columns
```

Entrée [5]: #vérification du nombre d'observation et du nombre de variables smp.shape

Out[5]: (799, 26)

Entrée [6]: smp.dtypes# les types des variables dans la base

```
Out[6]: age
                              float64
             prof
                               object
             duree
                              float64
             discip
                              float64
             n.enfant
                              float64
             n.fratrie
                                int64
             ecole
                              float64
             separation
                              float64
                              float64
             juge.enfant
             place
                              float64
             abus
                              float64
                              float64
             grav.cons
                                int64
             dep.cons
             ago.cons
                                int64
                                int64
             ptsd.cons
             alc.cons
                                int64
             subst.cons
                                int64
             scz.cons
                                int64
             char
                              float64
                              float64
             rs
                              float64
             ed
                              float64
             dr
                              float64
             suicide.s
             suicide.hr
                              float64
                              float64
             suicide.past
             dur.interv
                              float64
             dtype: object
Entrée [7]:
            # recodation des variables qualitatives
             def duree(series):
                 if series==1.0:
                     return 'Moins de 1 mois'
                 if series==2.0:
                     return '1 à 6 mois'
                 if series==3.0:
                     return '6 mois à 1 an'
                 if series==4.0:
                     return '1 à 5 ans'
                 if series==5.0:
                     return '5 ans ou plus'
                 else:
                     return series
             smp['duree']=smp['duree'].apply(duree)
             def discip1(series):
                 if series==0.0:
```

```
return 'non'
    if series==1.0:
        return 'oui'
    else:
        return series
smp['discip']=smp['discip'].apply(discip1)
def ecole(series):
    if series==1.0:
        return 'sans diplome'
    if series==2.0:
        return 'college'
    if series==3.0:
        return 'CAP, BEP'
    if series==4.0:
        return 'Lycee'
    if series==5.0:
        return 'universite'
    else:
        return series
smp['ecole']=smp['ecole'].apply(ecole)
def separation(series):
    if series==0.0:
        return 'non'
    if series==1.0:
        return 'oui'
    else:
        return series
smp['separation']=smp['separation'].apply(separation)
def jugeenfant(series):
    if series==0.0:
        return 'non'
    if series==1.0:
        return 'oui'
    else:
        return series
smp['juge.enfant']=smp['juge.enfant'].apply(jugeenfant)
def place(series):
    if series==0.0:
        return 'non'
    if series==1.0:
        return 'oui'
    else:
        return series
smp['place']=smp['place'].apply(place)
```

```
def abus(series):
    if series==0.0:
        return 'non'
    if series==1.0:
        return 'oui'
    else:
        return series
smp['abus']=smp['abus'].apply(abus)
def gravcons(series):
    if series==1.0:
        return 'normal'
    if series==2.0:
        return 'limite'
    if series==3.0:
        return 'légèrement'
    if series==4.0:
        return 'modérément'
    if series==5.0:
        return 'manifestement'
    if series==6.0:
        return 'gravement'
    if series==7.0:
        return 'parmi les patients les plus malades'
    else:
        return series
smp['grav.cons']=smp['grav.cons'].apply(gravcons)
def depcons(series):
    if series==0.0:
        return 'non'
    if series==1.0:
        return 'oui'
    else:
        return series
smp['dep.cons']=smp['dep.cons'].apply(depcons)
def agocons(series):
    if series==0.0:
        return 'non'
    if series==1.0:
        return 'oui'
    else:
        return series
smp['ago.cons']=smp['ago.cons'].apply(agocons)
def ptsdcons(series):
    if series==0.0:
        return 'non'
    if series==1.0:
```

```
return 'oui'
    else:
        return series
smp['ptsd.cons']=smp['ptsd.cons'].apply(ptsdcons)
def alccons(series):
    if series==0.0:
        return 'non'
    if series==1.0:
        return 'oui'
    else:
        return series
smp['alc.cons']=smp['alc.cons'].apply(alccons)
def substcons(series):
    if series==0.0:
        return 'non'
    if series==1.0:
        return 'oui'
    else:
        return series
smp['subst.cons']=smp['subst.cons'].apply(substcons)
def sczcons(series):
    if series==0.0:
        return 'non'
    if series==1.0:
        return 'oui'
    else:
        return series
smp['scz.cons']=smp['scz.cons'].apply(sczcons)
def char(series):
    if series==1.0:
        return 'absent'
    if series==2.0:
        return 'léger'
    if series==3.0:
        return 'moyen'
    if series==4.0:
        return 'sévère'
    else:
        return series
smp['char']=smp['char'].apply(char)
def rs(series):
    if series==1.0:
        return 'faible'
    if series==2.0:
```

```
return 'modéré'
    if series==3.0:
        return 'élevé'
    else:
        return series
smp['rs']=smp['rs'].apply(rs)
def ed(series):
    if series==1.0:
        return 'faible'
    if series==2.0:
        return 'modéré'
    if series==3.0:
        return 'élevé'
    else:
        return series
smp['ed']=smp['ed'].apply(ed)
def dr(series):
    if series==1.0:
        return 'faible'
    if series==2.0:
        return 'modéré'
    if series==3.0:
        return 'élevé'
    else:
        return series
smp['dr']=smp['dr'].apply(dr)
def suicidehr(series):# Je suis pas sure de cette recodage
    if series==0.0:
        return 'non'
    if series==1.0:
        return 'oui'
    else:
        return series
smp['suicide.hr']=smp['suicide.hr'].apply(suicidehr)
def suicidepast(series):
    if series==0.0:
        return 'non'
    if series==1.0:
        return 'oui'
    else:
        return series
smp['suicide.past']=smp['suicide.past'].apply(suicidepast)
```

SQ.3

Entrée [8]: , 'alc.cons', 'subst.cons', 'scz.cons', 'char', 'rs', 'ed', 'dr', 'su

Entrée [9]: print(list1)

	age	n.enfant	n.fratrie	dur.interv
0	31.0	2.0	4	NaN
1	49.0	7.0	3	70.0
2	50.0	2.0	2	NaN
3	47.0	0.0	6	105.0
4	23.0	1.0	6	NaN
794	28.0	1.0	4	60.0
795	44.0	1.0	12	105.0
796	31.0	3.0	6	105.0
797	38.0	0.0	1	75.0
798	71.0	2.0	4	45.0

[799 rows x 4 columns]

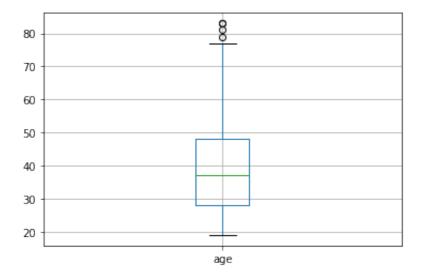
Entrée [10]: list1.describe()

Out[10]:

	age	n.enfant	n.fratrie	dur.interv
count	797.000000	773.000000	799.000000	749.000000
mean	38.899624	1.755498	4.286608	61.891856
std	13.280978	1.834044	3.441485	19.669605
min	19.000000	0.000000	0.000000	0.000000
25%	28.000000	0.000000	2.000000	48.000000
50%	37.000000	1.000000	3.000000	60.000000
75%	48.000000	3.000000	6.000000	75.000000
max	83.000000	13.000000	21.000000	120.000000

Entrée [11]: smp.boxplot(column='age')

Out[11]: <matplotlib.axes._subplots.AxesSubplot at 0x1175065d0>



SQ.5

Entrée [12]: smp.loc[(smp['prof']=="agriculteur")&(smp['n.enfant']>2.0),:]

Out[12]:

	age	prof	duree	discip	n.enfant	n.fratrie	ecole	separation	juge.enfant	р
14	64.0	agriculteur	NaN	non	3.0	2	sans diplome	non	non	
311	42.0	agriculteur	1 à 5 ans	non	3.0	6	sans diplome	non	non	
390	36.0	agriculteur	1 à 5 ans	oui	3.0	4	CAP,BEP	oui	oui	
441	79.0	agriculteur	5 ans ou plus	non	5.0	6	college	non	non	

4 rows × 26 columns

SQ.6

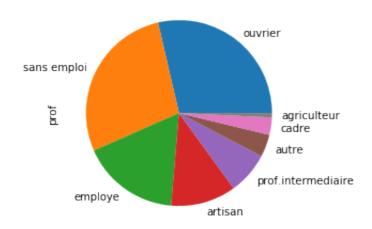
Entrée [13]: liste2=smp['prof'].value_counts()

```
Entrée [14]: print(liste2)
                                    227
             ouvrier
              sans emploi
                                    222
             employe
                                     135
              artisan
                                      90
             prof.intermediaire
                                      58
             autre
                                      31
              cadre
                                      24
             agriculteur
                                       6
             Name: prof, dtype: int64
Entrée [15]: liste2.sum()
    Out[15]: 793
Entrée [16]: liste2=(liste2/793)*100
Entrée [17]: print(liste2)
             ouvrier
                                    28.625473
                                    27.994956
              sans emploi
                                    17.023960
             employe
             artisan
                                     11.349306
              prof.intermediaire
                                      7.313997
             autre
                                      3,909206
                                      3.026482
              cadre
              agriculteur
                                      0.756620
             Name: prof, dtype: float64
```

Entrée [18]: # la catégorie ouvrier a le plus grand pourcentage, ainsi c'est la

Entrée [19]: liste2.plot.pie()

Out[19]: <matplotlib.axes._subplots.AxesSubplot at 0x1a1a8c2fd0>



SQ.8

Entrée [20]:	pd.crosstab(s	smp['	prof	'],s	mp['a	age']	, val	.ues=	smp['age'] , ag	gfı	ınc=p	d.Se	r
Out[20]:	age	19.0	20.0	21.0	22.0	23.0	24.0	25.0	26.0	27.0	28.0		69.0	70.0	•
	prof														
	agriculteur	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN		NaN	NaN	1
	artisan	NaN	20.0	NaN	NaN	NaN	24.0	NaN	26.0	27.0	28.0		NaN	NaN	-
	autre	19.0	20.0	21.0	NaN	23.0	24.0	25.0	26.0	27.0	NaN		NaN	70.0	-
	cadre	NaN	NaN	NaN	NaN	NaN	NaN	25.0	NaN	NaN	NaN		NaN	NaN	1
	employe	19.0	20.0	21.0	22.0	23.0	24.0	25.0	26.0	27.0	28.0		NaN	NaN	-
	ouvrier	19.0	20.0	21.0	22.0	23.0	24.0	25.0	26.0	27.0	28.0		69.0	NaN	-
	prof.intermediaire	19.0	NaN	NaN	22.0	NaN	NaN	NaN	26.0	27.0	28.0		NaN	NaN	1
	sans emploi	19.0	20.0	21.0	22.0	23.0	24.0	25.0	26.0	27.0	28.0		NaN	NaN	1

8 rows × 60 columns

SQ.9

Entrée []:

Entrée []:

SQ.11

Entrée [21]: smp.dropna(inplace=True)

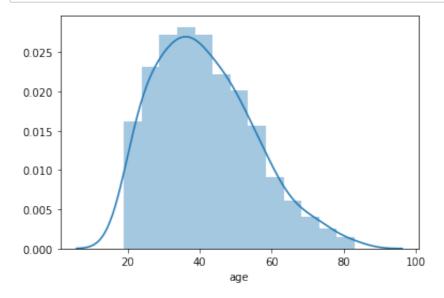
Entrée [22]: print(smp)

ratr	age ie \		prof			dı	uree	discip	n.enfant	n.f
7	52.0		artisan	5	ans	ou p	olus	non	2.0	
9	42.0		ouvrier		1	à 5	ans	oui	1.0	
12 12 3	21.0		employe		1	à 5	ans	non	0.0	
13 5	40.0		artisan		1	à 5	ans	non	3.0	
16 4	60.0	prof.inte	rmediaire	5	ans	ou p	olus	non	2.0	
• •							• • •	• • • •		
793	27.0	prof.inte	rmediaire		1	à 5	ans	non	2.0	
0 795	44.0		ouvrier		1	à 5	ans	oui	1.0	
12 796	31.0		cadre		1	à 5	ans	non	3.0	
6 797	38.0		employe	5	ans	ou p	olus	non	0.0	
1 798 4	71.0		autre		1	à 5	ans	non	2.0	
		ecole se	paration j	ug	e.en1	fant	plad	e	subst.cons	SCZ
.con 7	is \	college	non			non	no	on	non	
non 8	sans	diplome	oui			oui	no	on	oui	
non 12		college	oui			oui	Οl	ıi	oui	
non 13	sans	diplome	non			oui	no	n	non	
non 16		college	oui			non	οι	ıi	non	
non ••										
793		college	oui			non	Οl	ıi	non	
non 795		college	non			non	no	n	non	

non 796 non 797 non 798 non		Lycee P,BEP plome	oui non oui		oui non non	oui non non		oui non non
ast 7 non 8 oui 12 non	char \ absent sévère absent	rs modéré élevé modéré	ed modéré élevé modéré	dr modéré faible modéré	suici	0.0 4.0 0.0	suicide.hr non oui non	suicide.p
13 oui 16 non	absent absent	modéré faible	modéré modéré	modéré élevé		0.0	non non	
793 non 795 oui 796 non	absent absent léger	élevé faible faible	faible faible	faible faible		0.0 0.0 1.0	non non	
797 non 798 non	absent faible absent faible		faible faible	faible faible		0.0	non	
7 8 12 13 16 793 795 796 797	95 90 90	.0						

[403 rows x 26 columns]

Entrée [23]: sns.distplot(smp['age'], kde=True);



SQ.13

```
Entrée [40]: bins = [19.0, 28.0, 37.0, 48.0,83.0] smp['age_classe'] = pd.cut(smp['age'], bins)
```

SQ.14

```
Entrée [46]: liste4=smp['age_classe'].value_counts()
liste4=(liste4/400)*100
print(liste4)
```

```
(48.0, 83.0]29.25(37.0, 48.0]27.00(28.0, 37.0]25.00(19.0, 28.0]18.75
```

Name: age_classe, dtype: float64